INFORME TÉCNICO DE INFRAESTRUCTURA Y HARDWARE

DIMENSIONAMIENTO DE SERVIDOR, GPU Y GUÍA DE HABILITACIÓN

Ecosistema Soberano Noraltu IA & Susy Bot | Análisis Promedio y Bajo | Blindaje y Seguridad

Proyecto / Ecosistema:	Noraltu IA & Susy Bot Municipal (MyJNexoraVisual - Ituzaingó, Corrientes)
Propósito del Documento:	Evaluación y dimensionamiento de servidor físico dedicado para cómputo local de IA
Nivel de Seguridad:	TÉCNICA DE INFRAESTRUCTURA (Preservación estricta de propiedad intelectual y claves)
Marco Normativo:	Ley 25.326 de Protección de Datos Personales y Ley 11.723 de Propiedad Intelectual

1. Resumen Ejecutivo y Diagnóstico Técnico

El presente informe establece las especificaciones de hardware, tarjeta gráfica (GPU) y directivas técnicas para acondicionar un servidor físico dedicado ofrecido por un colaborador. El objetivo es correr localmente el ecosistema de IA integrado por **Noraltu IA** y **Susy Bot** con **soberanía tecnológica total, costo $0 y estricta privacidad**, impidiendo que datos sensibles de estudiantes y ciudadanos salgan de la infraestructura propia.

2. Comparativa Arquitectónica: Noraltu IA vs. Susy Bot

Ambos proyectos derivan del mismo núcleo soberano desacoplado, pero responden a propósitos especializados:

Dimensión	Noraltu IA (Educativo & Multimodal)	Susy Bot (Municipal & Ciudadano)
Propósito Central	Docente universal, cátedra universitaria, inclusión TEA/DUA y periodismo cívico.	Directora virtual de atención al vecino, trámites municipales y ordenanzas.
Visión en Vivo	Cámara Titán Live (pizarrones, textos didácticos, análisis hud interactivo).	Lazarillo Espacial Urbano (referencias reloj 12 en punto, lectura de DNI y tasas).
Reclamos y Servicios	Guía comercial local, clasificados, promociones y bolsa de trabajo.	Módulo de tickets #ITU-XXX (luminarias, bacheo, bromatología, defensa civil).
Audio y Fonética	Whisper cuántico (<200ms) y sintetizador fonético neutro.	Sintetizador cálido litoraleño, wake-word local y soporte gateway radio/mesh.
Base de Datos / RAG	pgvector sobre artículos, guías y secuencias didácticas.	pgvector + GraphRAG municipal (ordenanzas, áreas comunales).
Despliegue	Híbrido (PWA offline WebGPU + Servidor de Alta Capacidad).	100% On-Premise dentro de la red municipal protegida.

3. Por qué la GPU y la VRAM son el Factor Determinante

En la ejecución de IA generativa con modelos de pesos abiertos (LLaMA 3.3, Qwen 2.5, Whisper), el componente crítico es la **VRAM (Memoria de Video Dedicada)** de la tarjeta gráfica y su ancho de banda en GB/s. La memoria RAM estándar del servidor transfiere entre 30 y 80 GB/s, mientras que la VRAM de una tarjeta NVIDIA opera entre 500 y 1.000 GB/s (15x a 25x más veloz). Si un modelo corre en CPU/RAM, la velocidad se reduce a 2-4 palabras por segundo; en GPU, alcanza 35-70 palabras por segundo con fluidez humana instantánea. Asimismo, se requiere suficiente VRAM para que coexistan el LLM de texto, el modelo de visión y Whisper sin demoras de swap en disco.

4. Dimensionamiento del Servidor: Nivel Promedio y Nivel Bajo

4.1. Nivel Bajo / Mínimo Viable (Piloto, Pruebas y Desarrollo)

Tarjeta Gráfica (GPU)	NVIDIA GeForce RTX 3060 (12 GB VRAM) o RTX 4060 Ti (16 GB VRAM). Servidor Rack: Tesla T4 (16 GB).
VRAM Mínima Dedicada	12 GB a 16 GB GDDR6 dedicada (imprescindible para modelos de 8B + Visión).
CPU y Memoria RAM	Intel Core i7 (10ª gen+) / AMD Ryzen 7 (8 núcleos / 16 hilos) | 32 GB RAM DDR4/DDR5.
Almacenamiento	500 GB a 1 TB SSD NVMe M.2 (Lectura > 3.000 MB/s). Evitar discos mecánicos.
Fuente de Poder (PSU)	650W a 750W con certificación 80 Plus Gold.
Modelos Soportados y Capacidad	LLaMA 3.1 8B (Q4 ~5.5 GB) + LLaMA 3.2 11B Vision (Q4) + Whisper Medium + nomic-embed-text. Capacidad: 3 a 8 usuarios simultáneos a 35-50 tokens/segundo.

4.2. Nivel Promedio / Recomendado (Máximo Potencial y Producción Real)

Tarjeta Gráfica (GPU)	Opción A: 1x NVIDIA RTX 3090 / 4090 (24 GB VRAM) | Opción B (Óptima 70B): 2x RTX 3090 (48 GB VRAM combinada) | Enterprise: NVIDIA RTX A5000 / A6000.
VRAM Recomendada	24 GB (Single GPU para 32B y 70B híbrido) o 48 GB (Dual GPU para 70B nativo 100% en VRAM).
CPU y Memoria RAM	AMD Ryzen 9 7900X / Core i9 (16 a 24 núcleos) o AMD EPYC / Xeon Gold | 64 GB a 128 GB DDR5 ECC.
Almacenamiento	2 TB SSD NVMe PCIe 4.0 (Lectura > 6.500 MB/s). Permite cargar modelos de 40 GB en 6 segundos.
Fuente y Respaldo	1.000W a 1.200W 80 Plus Platinum + Sistema UPS (SAI) 1500VA/2000VA con onda senoidal pura.
Modelos Soportados y Capacidad	LLaMA 3.3 70B Instruct (Q4 ~42 GB) o Qwen 2.5 32B + Qwen 2.5-VL 7B / LLaMA 3.2 Vision + Whisper Large v3 Turbo + bge-m3. Capacidad: 25 a 50 usuarios concurrentes a 45-70 tokens/segundo sin cortes.

5. Guía de Despliegue en el Servidor (Blindaje y Cero Exposición)

Comandos estandarizados para configurar el servidor de tu amigo sin comprometer código fuente ni claves maestras:

Paso 1: Drivers NVIDIA y CUDA

```
sudo apt update && sudo apt install -y build-essential dkms nvidia-driver-550-server
nvidia-utils-550-server
Verificar reconocimiento ejecutando: nvidia-smi
```

Paso 2: Motor de Inferencia Ollama

```
curl -fsSL https://ollama.com/install.sh | sh && sudo systemctl enable --now ollama
```

Paso 3: Descarga de Modelos Abiertos Soberanos

```
# Nivel Bajo: ollama pull llama3.1:8b && ollama pull llama3.2-vision && ollama pull nomic-embed-text
# Nivel Alto: ollama pull llama3.3:70b && ollama pull qwen2.5-vl && ollama pull nomic-embed-text
```

Paso 4: Base de Datos pgvector (Docker Aislado en Localhost)

```
docker run -d --name nora-db --restart always -e POSTGRES_DB=noraitu_db -e POSTGRES_USER=nora_admin \
-e POSTGRES_PASSWORD=PASSWORD_SEGURA -p 127.0.0.1:5432:5432 -v nora_pgdata:/var/lib/postgresql/data
pgvector/pgvector:pg16
```

Paso 5: Despliegue de la Aplicación (Next.js con PM2)

```
npm install -g pm2 && npm run build && pm2 start npm --name 'noraitu-server' -- start -- -p 3000 && pm2
save
```

6. Protocolo de Blindaje de Seguridad y Protección de Datos

- **Aislamiento de Puertos (UFW):** Ollama (11434) y PostgreSQL (5432) deben escuchar únicamente en 127.0.0.1. El firewall solo debe abrir los puertos 80 y 443 al exterior.
- **Variables de Entorno Seguras:** Las credenciales residen en .env.production local con permisos restringidos (chmod 600). Prohibido comitear llaves a repositorios Git.
- **Secreto de Propiedad Intelectual:** En servidores compartidos con terceros, desplegar la aplicación pre-compilada (.next build o Docker container) sin transferir los archivos TypeScript (.ts, .tsx) originales ni las directivas de blindaje constitucional.
- **Cumplimiento Normativo:** Se respeta la Ley 25.326 de Protección de Datos Personales; ningún dato de estudiantes o vecinos sale del servidor.

7. Checklist y Preguntas Clave para el Amigo del Servidor

- **[ ]** 1. ¿El chasis es tipo torre o rack 4U? (Racks 1U/2U delgados no admiten tarjetas gráficas estándar por falta de altura).
- **[ ]** 2. ¿La fuente tiene conectores PCIe de 8 pines libres y cuántos Watts ofrece? (Mínimo 650W para 3060, 1000W para 3090/4090).
- **[ ]** 3. ¿La placa madre tiene ranura PCIe 4.0 x16 y soporte de Resizable BAR en el BIOS?
- **[ ]** 4. ¿Cuánta memoria RAM física tiene instalada el equipo y si es expandible? (Piso mínimo 32 GB, ideal 64 GB).
- **[ ]** 5. ¿Tiene ranuras para almacenamiento SSD NVMe M.2 de alta velocidad?

MyJNexoraVisual | *Dirección de Tecnología e Infraestructura de IA Soberana* | *Ituzaingó, Corrientes*